



SÃO PAULO
GOVERNO DO ESTADO

FACULDADE DE TECNOLOGIA DE BAURU
TECNOLOGIA EM BANCO DE DADOS

**Transformar Base de Dados Públicas em
Bancos de Dados Acessível à Sociedade**

Equipe:

Antonio Ranazzi Neto
Luis Victor Rosa de Almeida Santana Videira

Bauru/SP
2026

Transformar Base de Dados Públicas em Bancos de Dados Acessível à Sociedade

Equipe:

**Antonio Ranazzi Neto
Luis Victor Rosa de Almeida Santana Videira**

Projeto de pesquisa apresentado como requisito para aprovação na disciplina Laboratório de Desenvolvimento de Banco de Dados V do curso de Tecnologia em Banco de Dados, Faculdade de Tecnologia de Bauru.

SUMÁRIO

1. INTRODUÇÃO.....	4
2. DESCRIÇÃO DA BASE DE DADOS.....	4
3. JUSTIFICATIVA DA ESCOLHA DA BASE.....	5
3.1. Justificativa Técnica.....	5
3.2. Justificativa Social.....	5
4. AVALIAÇÃO TÉCNICA E SOCIAL DA BASE.....	6
4.1. Avaliação Técnica.....	6
4.2. Avaliação Social.....	6
5. PÚBLICO BENEFICIADO.....	7
6. OBJETIVOS DO PROJETO.....	7
6.1. Objetivo Geral.....	7
6.2. Objetivos Específicos.....	7
7. PROCESSO DE COLETA (Extract).....	8
7.1. Modelagem da Área de Staging.....	8
8. PROCESSO DE TRANSFORMAÇÃO (Transform).....	9
9. PROCESSO DE CARGA (Load).....	9
10. MODELAGEM DIMENSIONAL DO DATA WAREHOUSE.....	10
11. CÓDIGOS.....	12
11.1. Procedure da Dimensão Modalidade de Ensino.....	12
11.2. Procedure da Fato Enade.....	13
11.3. Aplicabilidade.....	15
12. CONCLUSÃO E VALOR SOCIAL.....	17

1. INTRODUÇÃO

A crescente transparência governamental tem impulsionado a abertura de grandes volumes de dados públicos, criando uma oportunidade única para que estudantes de tecnologia apliquem seus conhecimentos em prol da coletividade. No âmbito da disciplina Laboratório de Desenvolvimento de Banco de Dados V, este projeto de extensão busca transcender as barreiras acadêmicas, utilizando ferramentas de engenharia de dados para auditar e organizar informações de interesse social. A proposta central é transformar dados brutos e complexos em estruturas de informação organizadas, que permitam à sociedade civil compreender melhor a realidade educacional do país.

Nesta primeira etapa, o foco reside na seleção criteriosa de uma fonte de dados oficial e na fundamentação técnica e social de sua escolha. O trabalho propõe um diagnóstico sobre como a estruturação correta de dados pode revelar disparidades e guiar melhorias no ensino superior brasileiro, conectando a teoria de bancos de dados à prática da responsabilidade social.

2. DESCRIÇÃO DA BASE DE DADOS

Para a execução deste projeto, foi selecionada a base de dados do Conceito Enade 2023, gerida pelo Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (INEP).

Esta base é um dos pilares da regulação do ensino superior no Brasil e oferece um retrato detalhado do desempenho acadêmico em nível nacional.

Características da base:

- **Tema:** Indicadores de qualidade e desempenho acadêmico dos cursos de graduação no Brasil.
- **Origem:** Dados Abertos do INEP/MEC, acessíveis via portal oficial do Governo Federal.
- **Formato:** Arquivo estruturado em XLSX, contendo métricas de desempenho e identificadores institucionais.
- **Período:** Ciclo avaliativo referente ao ano de 2023.
- **Finalidade original:** Monitorar o cumprimento das diretrizes curriculares e a qualidade da formação oferecida pelas Instituições de Ensino Superior (IES).

A base é composta por variáveis geográficas, administrativas e acadêmicas, permitindo uma análise profunda sobre como fatores externos influenciam a qualidade da formação profissional em diferentes contextos.

3. JUSTIFICATIVA DA ESCOLHA DA BASE

3.1. Justificativa Técnica

A seleção do Conceito Enade 2023 como objeto de estudo fundamenta-se em requisitos técnicos essenciais para a disciplina de Banco de Dados:

- **Estrutura Multidimensional:** A base permite a criação de modelos relacionais complexos, envolvendo entidades como IES, Cursos, Municípios e Notas;
- **Necessidade de ETL:** Os dados brutos exigem processos rigorosos de extração e limpeza, especialmente para padronizar as nomenclaturas de cursos da área de tecnologia;
- **Potencial de Normalização:** A redundância presente nos arquivos originais oferece um excelente cenário para a aplicação de formas normais e otimização de armazenamento;
- **Volume de Dados:** A quantidade de registros é ideal para testar a performance de consultas e a integridade referencial do sistema a ser desenvolvido;
- **Consistência Oficial:** Por ser uma fonte governamental, os dados possuem uma estrutura semântica bem definida, facilitando a modelagem do dicionário de dados.

3.2. Justificativa Social

Do ponto de vista social, a escolha justifica-se pela necessidade urgente de transparência sobre a qualidade da formação em tecnologia no Brasil. Em um cenário de alta demanda por profissionais de TI, entender onde estão os *gaps* de ensino é uma questão de interesse público.

A análise estruturada desses dados contribui para:

- **Democratização da Informação:** Traduzir indicadores técnicos complexos em informações compreensíveis para pais e estudantes;
- **Auditoria da Modalidade EAD:** Comparar de forma imparcial se o crescimento do ensino a distância está sendo acompanhado pela manutenção da qualidade acadêmica;
- **Redução de Desigualdades Regionais:** Identificar áreas do país que sofrem com a carência de ensino tecnológico de excelência;
- **Apoio à Gestão Pública:** Fornecer subsídios baseados em dados para que órgãos reguladores possam intervir em cursos com desempenho crítico.

4. AVALIAÇÃO TÉCNICA E SOCIAL DA BASE

4.1. Avaliação Técnica

- **Formato:** XLSX (Excel Open XML), compatível com a maioria das ferramentas de integração de dados.
- **Volume:** Abrangência nacional, cobrindo todas as áreas do conhecimento avaliadas no ciclo 2023.
- **Atualização:** Dados consolidados anualmente, garantindo a atualidade do diagnóstico.
- **Confiabilidade:** Alta, por se tratar de um dado oficial utilizado para regulação e credenciamento de IES.
- **Licenciamento:** Aberto, permitindo o reuso e a transformação dos dados para fins acadêmicos e sociais.

4.2. Avaliação Social

A base possui alta relevância por impactar diretamente o futuro profissional de milhares de cidadãos. A transparência nos dados do Enade permite que a sociedade exerça seu papel de fiscalizadora da qualidade educacional. Além disso, ao estruturar esses dados, o projeto auxilia na identificação de tendências de mercado e na valorização do diploma de instituições que mantêm altos padrões de ensino, promovendo uma meritocracia baseada em evidências.

5. PÚBLICO BENEFICIADO

Os principais beneficiários deste projeto de extensão são:

- **Comunidade Estudantil:** Jovens que necessitam de dados confiáveis para escolher sua trajetória acadêmica;
- **Gestores de IES:** Que podem utilizar o banco de dados para realizar benchmarking e melhorias internas;
- **Sociedade Civil:** Que ganha uma ferramenta de controle social sobre a qualidade do ensino financiado ou regulado pelo Estado.

6. OBJETIVOS DO PROJETO

6.1. Objetivo Geral

Estruturar um banco de dados relacional a partir dos indicadores do Enade 2023, visando diagnosticar e dar transparência à qualidade do ensino de tecnologia nas diferentes regiões e modalidades do Brasil.

6.2. Objetivos Específicos

- Implementar rotinas de limpeza e transformação de dados para isolar os cursos de TI;
- Modelar e povoar um banco de dados normalizado que suporte consultas analíticas;
- Produzir um relatório comparativo entre o desempenho de cursos presenciais e EAD;
- Identificar correlações entre a localização geográfica das instituições e suas respectivas notas no Enade.

7. PROCESSO DE COLETA (Extract)

A coleta dos dados foi realizada através de download manual do arquivo XLSX oficial no portal do INEP na data de 17/04/2026. Após a obtenção do arquivo, procedeu-se com uma análise manual para garantir a integridade dos dados, o que incluiu:

- Exibição de Colunas Ocultas: Identificação e reativação de atributos que estavam ocultos na planilha original, garantindo que nenhuma informação relevante fosse descartada.
- Padronização de Nomenclatura: Renomeação manual das colunas para um padrão técnico compatível com sistemas de banco de dados, eliminando espaços, acentos e caracteres especiais que dificultam a manipulação via SQL.

7.1. Modelagem da Área de Staging

Para suportar a carga dos dados, foi criada uma tabela de staging denominada stg.enade no PostgreSQL. A estrutura foi definida para preservar a fidelidade dos dados originais, utilizando tipos de dados apropriados para garantir a integridade numérica e de texto. Abaixo, o dicionário de dados técnico

Tabela:	stg.enade	
Descrição:	Armazena os dados brutos referentes ao desempenho dos estudantes no Enade 2023.	
Coluna	Tipo	Descrição
ano	INT	Ano de referência do ciclo.
cod_area	INT	Código da área de avaliação.
area_avaliacao	VARCHAR(35)	Descrição da área de avaliação.
grau_academico	VARCHAR(15)	Bacharelado, Licenciatura ou Tecnológico.
cod_ies	INT	Código único da IES no INEP.
nome_ies	VARCHAR(100)	Nome completo da IES.
sigla_ies	VARCHAR(15)	Sigla da IES.
organizacao_academica	VARCHAR(30)	Tipo de organização (Universidade, Centro, etc).
categoria_administrativa	VARCHAR(30)	Pública ou Privada.
cod_curso	INT	Código único do curso no INEP.
modalidade_ensino	VARCHAR(20)	Presencial ou EAD.
cod_municipio	INT	Código IBGE do município.
municipio_curso	VARCHAR(30)	Nome do município do curso.
sigla_uf	VARCHAR(2)	Unidade Federativa.
num_concluintes_inscritos	INT	Total de inscritos no exame.
num_concluintes_participantes	INT	Total de participantes efetivos.
nota_bruta_fg	FLOAT	Nota bruta Formação Geral.
nota_padronizada_fg	FLOAT	Nota padronizada Formação Geral.

Tabela:	stg.enade	
Descrição:	Armazena os dados brutos referentes ao desempenho dos estudantes no Enade 2023.	
Coluna	Tipo	Descrição
nota_bruta_ce	FLOAT	Nota bruta Componente Específico.
nota_padronizada_ce	FLOAT	Nota padronizada Componente Específico.
conceito_enade	FLOAT	Nota final contínua.
conceito_enade_faixa	INT	Conceito final (1-5).
entidade_cebas	VARCHAR(1)	Indicador de entidade filantrópica.

8. PROCESSO DE TRANSFORMAÇÃO (Transform)

Seguindo os princípios de Clean Code e Robustez, o processo de transformação (ETL) tratou os seguintes desafios técnicos:

- Tratamento de Nulos (Null Handling): Valores inconsistentes como "", "-", "NaN" ou nulos foram mapeados para NULL no PostgreSQL, evitando distorções em médias aritméticas futuras.
- Normalização de Tipos: Conversão rigorosa de strings para tipos numéricos (FLOAT/INT) com a remoção de separadores de milhar e ajuste de casas decimais para permitir operações matemáticas nativas no banco de dados.
- Integridade de Domínio: A coluna entidade_cebas foi padronizada para VARCHAR(1), garantindo economia de armazenamento e consistência de valores ('S'/'N').

9. PROCESSO DE CARGA (Load)

A carga dos dados foi realizada por meio de um processo ETL desenvolvido em Python, utilizando a biblioteca pandas para tratamento e padronização dos dados antes da inserção no banco PostgreSQL.

- Ferramenta: Python (pandas).
- Destino: Esquema stg, Tabela enade.
- Scripts de Apoio: Desenvolvemos scripts Python (etl_enade_sql.py) para validar a estrutura antes da carga final, garantindo o alinhamento com o contrato de dados definido no SQL. O script pode ser verificado através do link externo: https://drive.google.com/file/d/1Hhi48A45ViOMVyMWgNck_q7976jXM8eN/view?usp=drive_link

10. MODELAGEM DIMENSIONAL DO DATA WAREHOUSE

Com o objetivo de transformar os dados brutos disponibilizados pelo INEP em informações estruturadas para análise multidimensional, foi desenvolvido um pipeline ETL (Extract, Transform and Load) integrado a uma arquitetura de Data Warehouse relacional.

A Figura 1 apresenta o fluxo completo da arquitetura ETL/DW desenvolvida no projeto.

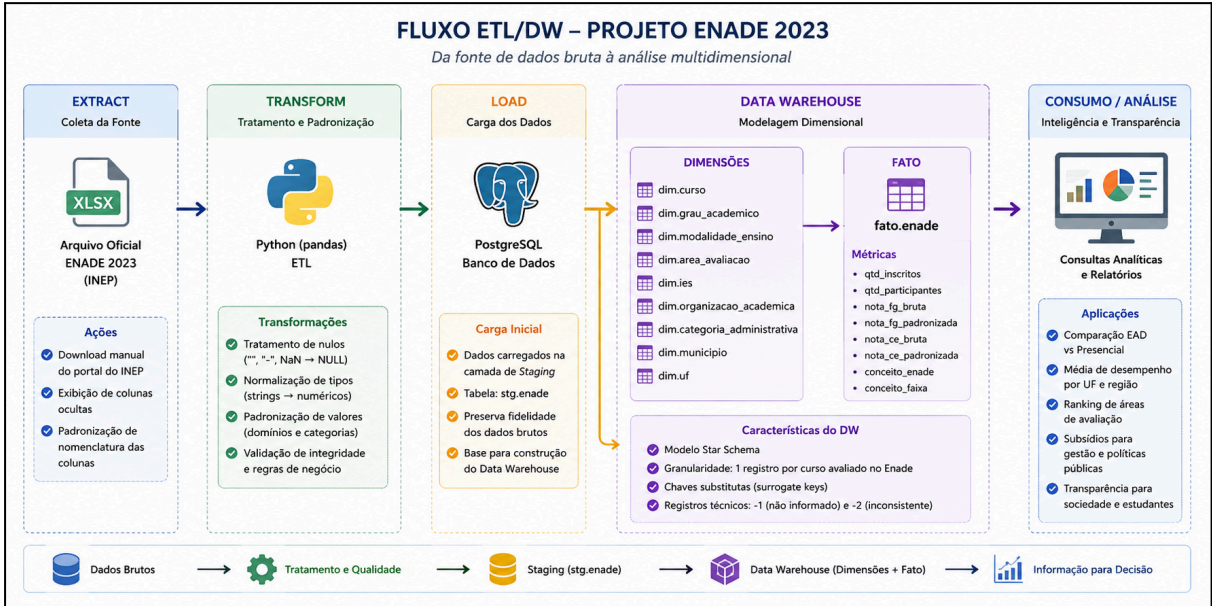


Figura 1 - Fluxo ETL/DW

O fluxo arquitetural do projeto inicia-se na extração dos microdados do Enade 2023, seguida pela etapa de transformação realizada em Python utilizando a biblioteca pandas, responsável pela limpeza, padronização e validação dos dados. Posteriormente, os dados tratados são carregados no PostgreSQL inicialmente na camada de staging, servindo como base para a construção das dimensões e da tabela fato do Data Warehouse.

A modelagem dimensional, apresentada na Figura 2, foi estruturada no paradigma Star Schema, permitindo consultas analíticas otimizadas e suporte à geração de indicadores educacionais, comparações regionais e análises estatísticas relacionadas ao desempenho do ensino superior brasileiro.




Figura 2 - DER Todas as Tabelas

A granularidade da tabela fato foi definida como: “1 registro por curso avaliado no Enade, associado a uma instituição de ensino, município, modalidade de ensino e ano de referência.”

A tabela fato concentra os indicadores quantitativos do Enade, armazenando métricas numéricas utilizadas em análises estatísticas e comparativas, como quantidade de concluintes, notas brutas, notas padronizadas e conceito final do Enade.

Foram criados registros técnicos padronizados nas dimensões para representar:

- Dados não informados (-1)
- Dados inconsistentes (-2)

11. CÓDIGOS

Visando a objetividade e a fluidez da leitura, a seção a seguir apresenta um exemplo representativo da estrutura de cada núcleo do banco de dados. A documentação técnica detalhada, contendo os códigos completos de todas as tabelas, incluindo tipos de dados, restrições de integridade e descrições funcionais de cada atributo, está disponível para consulta integral através do link externo:

https://drive.google.com/drive/folders/1G_Q8U3wvbbubGlgFIZA5lddu1j8e4rUF?usp=drive_link

11.1. Procedure da Dimensão Modalidade de Ensino

```
CREATE OR REPLACE PROCEDURE stg.p_dim_modalidade_ensino()
LANGUAGE plpgsql
AS $$
DECLARE
    v_qtd_registros INT;
    v_id_log INT;
BEGIN
    -- 1. Apaga a dimensão se já existir
    DROP TABLE IF EXISTS dim.modalidade_ensino;

    -- 2. Cria a dimensão consolidada
    CREATE TABLE dim.modalidade_ensino (
        id_modalidade INT GENERATED BY DEFAULT AS IDENTITY PRIMARY KEY,
        cod_modalidade INT UNIQUE,
        dsc_modalidade VARCHAR(100) NOT NULL
    );

    -- 3. Insere os valores padronizados (códigos oficiais do INEP)
    INSERT INTO dim.modalidade_ensino (cod_modalidade, dsc_modalidade)
    VALUES
        (1, 'PRESENCIAL'),
        (2, 'EDUCAÇÃO A DISTÂNCIA');

    -- 4. Insere registros padrão
    INSERT INTO dim.modalidade_ensino (id_modalidade, cod_modalidade,
    dsc_modalidade)
    VALUES
        (-1, -1, 'NÃO INFORMADO'),
        (-2, -2, 'DADO INCONSISTENTE');

END;
$$;
```

11.2. Procedure da Fato Enade:

```
CREATE OR REPLACE PROCEDURE stg.p_fato_enade()
LANGUAGE plpgsql
AS $$
BEGIN

    -- 1. Remove a fato anterior
    DROP TABLE IF EXISTS fato.enade;

    -- 2. Cria a tabela fato
    CREATE TABLE fato.enade (
        ano_referencia INT,
        id_curso INT,
        id_grau INT,
        id_modalidade INT,
        id_area_avaliacao INT,
        id_ies INT,
        id_org INT,
        id_categoria INT,
        id_municipio INT,
        id_uf INT,
        qtd_inscritos INT,
        qtd_participantes INT,
        nota_fg_bruta NUMERIC(10,2),
        nota_fg_padronizada NUMERIC(10,2),
        nota_ce_bruta NUMERIC(10,2),
        nota_ce_padronizada NUMERIC(10,2),
        conceito_enade NUMERIC(10,2),
        conceito_faixa INT
    );

    -- 3. Carga da fato
    INSERT INTO fato.enade (
        ano_referencia,
        id_curso,
        id_grau,
        id_modalidade,
        id_area_avaliacao,
        id_ies,
        id_org,
        id_categoria,
        id_municipio,
        id_uf,
        qtd_inscritos,
        qtd_participantes,
        nota_fg_bruta,
        nota_fg_padronizada,
        nota_ce_bruta,
        nota_ce_padronizada,
        conceito_enade,
        conceito_faixa
    )
```

```

SELECT
    -- Tempo
    e.ano AS ano_referencia,
    -- Chaves dimensionais
    COALESCE(dc.id_curso, -2) AS id_curso,
    COALESCE(dg.id_grau, -2) AS id_grau,
    COALESCE(dm.id_modalidade, -2) AS id_modalidade,
    COALESCE(da.id_area_avaliacao, -2) AS id_area_avaliacao,
    COALESCE(di.id_ies, -2) AS id_ies,
    COALESCE(doa.id_org, -2) AS id_org,
    COALESCE(dca.id_categoria, -2) AS id_categoria,
    COALESCE(dmu.id_municipio, -2) AS id_municipio,
    COALESCE(du.id_uf, -2) AS id_uf,
    -- Métricas
    e.num_concluintes_inscritos AS qtd_inscritos,
    e.num_concluintes_participantes AS qtd_participantes,
    e.nota_bruta_fg AS nota_fg_bruta,
    e.nota_padronizada_fg AS nota_fg_padronizada,
    e.nota_bruta_ce AS nota_ce_bruta,
    e.nota_padronizada_ce AS nota_ce_padronizada,
    e.conceito_enade,
    e.conceito_enade_faixa AS conceito_faixa
FROM stg.enade e

-- DIM_CURSO
LEFT JOIN dim.curso dc
    ON e.cod_curso = dc.cod_curso
-- DIM_GRAU_ACADEMICO
LEFT JOIN dim.grau_academico dg
    ON UPPER(TRIM(e.grau_academico)) = UPPER(TRIM(dg.dsc_grau_academico))
-- DIM_MODALIDADE_ENSINO
LEFT JOIN dim.modalidade_ensino dm
    ON UPPER(TRIM(e.modalidade_ensino)) = UPPER(TRIM(dm.dsc_modalidade))
-- DIM_AREA_AVALIACAO
LEFT JOIN dim.area_avaliacao da
    ON e.cod_area = da.cod_area
-- DIM_IES
LEFT JOIN dim.ies di
    ON e.cod_ies = di.cod_ies
-- DIM_ORGANIZACAO_ACADEMICA
LEFT JOIN dim.organizacao_academica doa
    ON UPPER(TRIM(e.organizacao_academica)) =
UPPER(TRIM(doa.dsc_organizacao_academica))
-- DIM_CATEGORIA_ADMINISTRATIVA
LEFT JOIN dim.categoria_administrativa dca
    ON UPPER(TRIM(e.categoria_administrativa)) = UPPER(TRIM(dca.dsc_categoria))
-- DIM_MUNICIPIO
LEFT JOIN dim.municipio dmu
    ON e.cod_municipio = dmu.cod_municipio
-- DIM_UF
LEFT JOIN dim.uf du
    ON UPPER(TRIM(e.sigla_uf)) = UPPER(TRIM(du.sigla_uf));
END;
$$;

```

11.3. Aplicabilidade

```
– Média por UF
SELECT
  du.nome_uf,
  ROUND(AVG(f.conceito_enade),2) AS media_enade
FROM fato.enade f
JOIN dim.uf du
  ON f.id_uf = du.id_uf
GROUP BY du.nome_uf
ORDER BY media_enade DESC
LIMIT 10;
```

nome_uf character varying (100)	media_enade numeric
ESPIRITO SANTO	3.09
RIO GRANDE DO SUL	2.68
CEARA	2.66
DISTRITO FEDERAL	2.58
SERGIPE	2.56
PARANA	2.55
SANTA CATARINA	2.52
RIO GRANDE DO NORTE	2.51
MINAS GERAIS	2.50
PARAIBA	2.49

Figura 2 - Resultados: Média por UF

```

– Top áreas de avaliação
SELECT
    da.area_avaliacao,
    ROUND(AVG(f.conceito_enade),2) AS media
FROM fato.enade f
JOIN dim.area_avaliacao da
    ON f.id_area_avaliacao = da.id_area_avaliacao
GROUP BY da.area_avaliacao
ORDER BY media DESC
LIMIT 10;

```

area_avaliacao character varying (250)	media numeric
MEDICINA	2.79
TECNOLOGIA EM ESTÉTICA E COSMÉTICA	2.66
NUTRIÇÃO	2.60
AGRONOMIA	2.54
ENGENHARIA AMBIENTAL	2.53
TECNOLOGIA EM GESTÃO AMBIENTAL	2.47
FONOAUDIOLOGIA	2.47
MEDICINA VETERINÁRIA	2.45
FISIOTERAPIA	2.45
ARQUITETURA E URBANISMO	2.44

Figura 3 - Resultados: Top áreas de avaliação

12. CONCLUSÃO E VALOR SOCIAL

Ao estruturar os dados em um banco de dados relacional (PostgreSQL), o projeto eleva o nível de acessibilidade da informação. Enquanto planilhas XLSX podem ser lentas e confusas para grandes volumes, uma base SQL permite:

- Consultas Rápidas: Filtragem instantânea de cursos por modalidade ou região.
- Auditoria Facilitada: Cruzamento de dados para identificar disparidades regionais no ensino de tecnologia.
- Interação com a Sociedade: Possibilidade de conectar ferramentas de visualização de dados (BI) para que o público leigo consuma os dados de forma gráfica e intuitiva.