

# **TRABALHO DE LABORATÓRIO DE DESENVOLVIMENTO DE BANCO DE DADOS V**

Período: 1º semestre de 2026 — 5º Semestre CST Banco de Dados

Professor: Luis Alexandre da Silva

Disciplina: Laboratório de Desenvolvimento de Banco de Dados V

Alunos: Egídio Brumati Dugaich, Leandra Cristiane Rosa e Samuel Ferreira de Azevedo

Projeto de Curricularização da Extensão

Modalidade: Parceiro Aberto (Modelo Universal)

Título do Projeto: Transformar Base de Dados Públicas em Banco de Dados Acessível à Sociedade

ETAPA 2 - Coleta, Limpeza e Preparação dos Dados (ETL)

## **RELATÓRIO TÉCNICO**

### **Coleta, Limpeza e Preparação dos Dados**

#### **1. Introdução**

Este relatório apresenta o processo de coleta, análise inicial, limpeza, padronização e consolidação dos dados utilizados no projeto.

O objetivo da Fase 2 foi transformar séries públicas do IPEADData em bases tratadas e organizadas, permitindo analisar a relação entre a variação dos preços de alimentos e bebidas e o rendimento médio real da população.

A proposta tem finalidade social, pois busca facilitar o uso de dados públicos para compreender períodos de maior pressão econômica sobre o acesso a alimentos.

#### **2. Bases de dados utilizadas**

Foram utilizadas duas séries públicas do IPEADData.

##### **2.1 IPCA — alimentos e bebidas**

- Código da série: PRECOS12\_IPCAAB12
- Descrição: IPCA - alimentos e bebidas - taxa de variação mensal
- Unidade: percentual ao mês
- Arquivo bruto gerado: dados/brutos/ipca\_alimentos\_bruto.csv

Essa série foi utilizada como base para calcular a variação acumulada dos preços de alimentos e bebidas por trimestre.

##### **2.2 Rendimento médio real**

- Código da série: PNADCT\_RRETUF
- Descrição: Rendimento médio real de todos os trabalhos efetivo
- Unidade: reais
- Arquivo bruto gerado: dados/brutos/rendimento\_real\_bruto.csv

Essa série foi utilizada como indicador da evolução do rendimento real da população.

### 3. Coleta dos dados

A coleta foi realizada de forma automatizada por meio da biblioteca Python `ipeadata.py`, que acessa as séries públicas do IPEADData.

O script responsável por essa etapa é:

```
scripts/01_coleta_ipea.py
```

Arquivos gerados na coleta:

- dados/brutos/ipca\_alimentos\_bruto.csv
- dados/brutos/rendimento\_real\_bruto.csv
- dados/brutos/registro\_coleta.csv

O arquivo `registro_coleta.csv` documenta:

- nome da base;
- código da série no IPEADData;
- fonte;
- método de coleta;
- data da coleta;
- arquivo gerado;
- finalidade social da base.

### 4. Análise inicial da qualidade dos dados

A análise inicial foi realizada pelo script:

```
scripts/02_analise_inicial.py
```

Foram verificados:

- quantidade de linhas e colunas;
- valores faltantes;
- linhas duplicadas;
- datas inválidas;
- datas duplicadas;
- valores mínimos e máximos;
- valores negativos;
- problemas estruturais.

Arquivos gerados:

- dados/tratados/diagnostico\_qualidade\_dados.csv
- dados/tratados/duplicidade\_datas\_ipca.csv
- dados/tratados/duplicidade\_datas\_rendimento.csv
- dados/tratados/analise\_inicial\_interpretativa.txt

#### 4.1 Resultado da análise — IPCA alimentos

A base bruta de IPCA alimentos apresentou:

- 547 registros;
- 7 colunas;
- 1 valor faltante;
- nenhuma linha duplicada;
- nenhuma data duplicada;
- período de 1980-10-01 até 2026-04-01;
- valor mínimo de -3,49%;
- valor máximo de 90,23%;
- 96 valores negativos.

Os valores negativos não foram considerados erro automaticamente, pois a série representa taxa de variação mensal. Nesse caso, valores negativos podem indicar queda nos preços de alimentos e bebidas em determinado mês.

O valor máximo elevado também foi mantido, pois a série histórica começa em 1980, período de inflação elevada no Brasil.

#### 4.2 Resultado da análise — rendimento real

A base bruta de rendimento real apresentou:

- 1848 registros;
- 7 colunas;
- nenhum valor faltante;
- 10 linhas duplicadas;
- 1792 datas duplicadas;
- período de 2012-01-01 até 2025-10-01;
- valor mínimo de R\$ 1.571,00;
- valor máximo de R\$ 6.534,00;
- nenhum valor negativo.

O principal problema estrutural identificado foi a existência de múltiplos registros para uma mesma data, sem uma coluna explícita indicando o recorte correspondente a cada linha.

Esse problema poderia prejudicar o uso social dos dados, pois usuários externos poderiam interpretar erroneamente os registros como uma única série já consolidada.

### 5. Limpeza e padronização dos dados

A limpeza e padronização foram realizadas pelo script:

```
scripts/03_limpeza_padronizacao.py
```

Arquivos gerados:

- dados/tratados/ipca\_alimentos\_tratado.csv

- dados/tratados/rendimento\_real\_tratado.csv
- dados/tratados/resumo\_limpeza\_padronizacao.csv

### **5.1 Tratamento aplicado ao IPCA alimentos**

Procedimentos realizados:

- padronização dos nomes das colunas;
- conversão da data para formato adequado;
- conversão da coluna de valor para tipo numérico;
- remoção de registros sem data ou sem valor;
- ordenação cronológica.

Resultado:

- 547 registros antes do tratamento;
- 546 registros após o tratamento;
- 1 registro removido.

### **5.2 Tratamento aplicado ao rendimento real**

Procedimentos realizados:

- padronização dos nomes das colunas;
- conversão da data para formato adequado;
- conversão da coluna de valor para tipo numérico;
- remoção de duplicidades exatas;
- agregação pela média dos registros disponíveis em cada data;
- ordenação cronológica.

Resultado:

- 1848 registros antes do tratamento;
- 56 registros após o tratamento;
- 1792 registros removidos ou agregados.

A agregação pela média foi adotada porque a API retornou múltiplos registros por data sem informar explicitamente o recorte correspondente a cada linha.

## **6. Consolidação da base final**

A base final foi gerada pelo script:

```
scripts/04_geracao_base_final.py
```

Arquivos gerados:

- dados/tratados/base\_consolidada\_pressao\_alimentar.csv
- dados/dicionario\_dados/dicionario\_base\_consolidada.csv
- dados/tratados/resumo\_base\_consolidada.txt

A série de IPCA alimentos possui periodicidade mensal, enquanto a série de rendimento real utilizada possui periodicidade trimestral. Para manter coerência temporal na comparação, o IPCA mensal foi convertido para variação acumulada trimestral por composição das taxas mensais.

A consolidação foi feita a partir do ano, trimestre e data de referência. A base final considera apenas o período comum entre as duas séries.

Resultado da base consolidada:

- 56 registros trimestrais;
- data mínima: 2012-01-01;
- data máxima: 2025-10-01.

## 7. Indicador de pressão alimentar

Foi criado um indicador simplificado para representar a pressão dos preços dos alimentos em relação à renda.

O indicador foi calculado como:

```
indicador_pressao_alimentar = IPCA de alimentos acumulado no trimestre -  
variação trimestral do rendimento real
```

Interpretação:

- valor positivo: os alimentos ficaram relativamente mais pressionados em relação à renda no trimestre;
- valor negativo ou zero: a variação da renda acompanhou ou superou a variação acumulada dos alimentos;
- valor maior ou igual a 1: alta pressão alimentar.

Classificações obtidas:

| Classificação     | Quantidade de períodos |
|-------------------|------------------------|
| Sem pressão       | 25                     |
| Alta pressão      | 24                     |
| Pressão moderada  | 6                      |
| Sem classificação | 1                      |

A primeira linha ficou sem classificação porque o cálculo da variação do rendimento depende do período anterior.

## 8. Dicionário da base consolidada

Foi criado um dicionário de dados para facilitar o uso da base por outros usuários.

Arquivo:

```
dados/dicionario_dados/dicionario_base_consolidada.csv
```

O dicionário descreve as colunas da base consolidada, seus tipos e significados.

Principais colunas:

- data\_referencia;
- ano;

- trimestre;
- mes;
- ipca\_alimentos\_acumulado\_trimestre\_pct;
- quantidade\_meses\_ipca\_no\_trimestre;
- rendimento\_real\_medio\_reais;
- rendimento\_real\_variacao\_trimestral\_pct;
- indicador\_pressao\_alimentar;
- classificacao\_pressao;
- quantidade\_registros\_agregados.

## **9. Impacto social da preparação dos dados**

A preparação dos dados contribui para tornar informações públicas mais acessíveis, organizadas e compreensíveis.

Antes do tratamento, os dados estavam em séries separadas e apresentavam problemas como valor faltante, duplicidades e múltiplos registros por data. Esses problemas poderiam dificultar análises feitas por estudantes, pesquisadores, jornalistas, organizações sociais ou cidadãos interessados em compreender a relação entre renda e custo dos alimentos.

Após o processo de ETL, foi gerada uma base consolidada e documentada, permitindo analisar de forma mais clara os períodos em que a inflação dos alimentos pressionou mais fortemente o rendimento real.

## **10. Conclusão**

A Fase 2 resultou na construção de uma base tratada, padronizada e consolidada a partir de dados públicos do IPEADData.

Foram gerados scripts ETL, arquivos brutos, arquivos tratados, diagnóstico de qualidade, dicionário de dados e uma base consolidada com indicador de pressão alimentar.

O processo atende ao objetivo extensionista do projeto ao transformar dados públicos dispersos em uma estrutura mais adequada para uso pela sociedade.