

Guia Rápido para a Sociedade

Base de dados agregados de casos e óbitos por COVID-19 no Estado de São Paulo: o que foi feito para deixar esses dados públicos mais confiáveis e fáceis de usar.

Os dados sobre casos de COVID-19 no estado de São Paulo são públicos e estão disponíveis para qualquer pessoa no site da Fundação SEADE:

<https://repositorio.seade.gov.br/dataset/covid-19-semanal/resource/cbbe434f-955f-4391-9eb7-5129078d8af5>. Mas, como costuma acontecer com grandes bases de dados oficiais, os mesmos acabam por apresentar vários problemas que dificultavam o uso no dia a dia. Este documento explica, em linguagem simples, o trabalho de limpeza e organização feito sobre essa base e principalmente, o que você precisa saber para usá-la com confiança.

O que foi feito

A base original, com mais de 6,7 milhões de registros de casos confirmados, foi baixada e trabalhada para que ficasse mais limpa e organizada. As principais melhorias realizadas foram:

- Padronização das datas, deixando todas no mesmo formato e fáceis de usar.
- Uniformização das informações que estavam escritas de formas diferentes, para que tudo seguisse um padrão único.
- Separação da lista de municípios em uma tabela própria, evitando repetição e reduzindo o risco de erros de digitação.
- Transparência em cada informação, se a mesma realmente existe e quando simplesmente não foi registrada na origem.

Porque isso foi necessário

Dados públicos quase sempre chegam “brutos”: com campos vazios, informações repetidas e formatos inconsistentes. Do jeito que estavam, era fácil chegar a conclusões erradas sem perceber. O trabalho de limpeza serve para que qualquer pessoa — pesquisadores, jornalistas, gestores públicos ou cidadãos curiosos — possa usar os números com segurança, sem precisar entender os detalhes técnicos por trás deles.

O que é precisa saber antes de usar

Uma parte importante do trabalho foi descobrir, com honestidade, os limites desses dados. Para usá-los de forma responsável, fique atento a três pontos:

- **As informações sobre doenças prévias estão quase todas em branco.** Em mais de 90% dos casos não foi registrado se a pessoa tinha diabetes, problema no coração ou outras condições. Por isso, esses campos não servem para dizer quantas pessoas tinham cada doença — o número apareceria muito menor do que a realidade.
- **Cada linha é uma notificação, e não necessariamente uma pessoa diferente.** A base não identifica os pacientes. Existem milhões de linhas idênticas, e muitas delas são, na verdade, pessoas diferentes que por acaso têm a mesma idade, sexo, cidade e data. Por isso, os números devem ser lidos como “registros”, e nada foi apagado, para não correr o risco de eliminar casos reais.
- **Algumas idades e datas não foram informadas.** Esses casos foram mantidos, apenas com o campo em branco, porque continuam úteis para outras análises (como distribuição por cidade ou por período).

Como isso ajuda a sociedade

Ao entregar uma base organizada e, sobretudo, ao deixar claro onde ela é confiável e onde não é, este trabalho permite que a informação pública seja reaproveitada com transparência. Em vez de cada pessoa ter que descobrir os problemas por conta própria, os dados já vêm acompanhados de um “guia de uso”. Assim, a informação pública fica mais perto de quem quer estudar a pandemia, embasar uma reportagem ou apoiar uma decisão — com a tranquilidade de saber exatamente o que cada número significa.

Trabalho realizado por

- Paulo Mateus Coelho Sacho
Graduando em Tecnologia de Banco de Dados pela FATEC Bauru
paulo.sacho@aluno.cps.sp.gov.br
- Gustavo Alonso Ziglio
Graduando em Tecnologia de Banco de Dados pela FATEC Bauru
gustavo.ziglio@aluno.cps.sp.gov.br
- Heitor Henrique Gutierrez
Graduando em Tecnologia de Banco de Dados pela FATEC Bauru
heitor.gutierrez@aluno.cps.sp.gov.br