

TRANSFORMANDO A BASE DE DADOS “CASOS, ÓBITOS E DOENÇAS PREEXISTENTES” EM UMA BASE ACESSÍVEL A SOCIEDADE

Paulo Mateus Coelho Sacho
Graduando em Tecnologia de Banco de Dados pela FATEC Bauru
paulo.sacho@aluno.cps.sp.gov.br

Gustavo Alonso Ziglio
Graduando em Tecnologia de Banco de Dados pela FATEC Bauru
gustavo.ziglio@aluno.cps.sp.gov.br

Heitor Henrique Gutierres
Graduando em Tecnologia de Banco de Dados pela FATEC Bauru
heitor.gutierres@aluno.cps.sp.gov.br

Relatório Técnico ETAPA 2: Coleta, Limpeza e Preparação dos Dados (ETL)

1 Objetivo

Este relatório documenta a aquisição, análise, limpeza, padronização e normalização de uma base pública de casos de COVID-19 do estado de São Paulo, com o objetivo de transformá-la em uma base estruturada, confiável e reutilizável pela sociedade. A base original possui 6.752.117 registros e 20 colunas, descrevendo casos confirmados de COVID-19, características demográficas dos pacientes, data de início dos sintomas, ocorrência de óbito e a presença de comorbidades e fatores de risco.

A etapa caracteriza-se como extensionista por preparar dados públicos para uso acessível, contribuindo para que organizações e cidadãos utilizem essas informações de forma confiável.

2. Coleta dos Dados

2.1 Documentação da fonte

Item	Descrição
Fonte da base de dados	https://repositorio.seade.gov.br/dataset/covid-19-semanal/re-source/4da62598-45e9-462d-8736-a5dc77b4017f
Data da coleta	16/06/2026
Formato original	CSV, separador “;”, codificação UTF-8
Volume da base de dados	6.752.117 registros, 20 colunas
Volume da amostra disponibilizada	100.000 registros, 20 colunas
Método de coleta	Download manual

2.2 Finalidade social da base

A base permite acompanhar a distribuição dos casos de COVID-19 por município, faixa etária, sexo e período, além da mortalidade associada e da presença de comorbidades. Disponibilizada com qualidade adequada, apoia decisões de saúde pública, pesquisa acadêmica, jornalismo de dados e o acompanhamento da pandemia por parte da população, de organizações sociais e de gestores públicos.

2.3 Dicionário de dados (estrutura original)

Coluna	Tipo observado	Descrição
nome_munic	texto	Nome do município de notificação
codigo_ibge	inteiro	Código IBGE do município
idade	inteiro (com nulos)	Idade do paciente em anos
cs_sexo	texto	Sexo (FEMININO / MASCULINO)
data_inicio_sintomas	texto (ISO + hora)	Data de início dos sintomas
obito	inteiro (0/1)	Indicador de óbito
asma ... síndrome_de_down	texto	13 colunas de comorbidades/fatores de risco (SIM / NÃO / IGNORADO)
diagnostico_covid19	texto	Resultado do diagnóstico

3 Análise Inicial dos Dados

Esta seção identifica os problemas de qualidade encontrados e descreve como cada um poderia prejudicar o uso dos dados pela sociedade. Todos os números foram apurados sobre a base completa de 6.752.117 registros.

3.1 Dados faltantes

Foram identificados valores ausentes registrados de duas formas:

Ausência explícita ('NA'). Três colunas contêm valores nulos: idade, com 219.248 nulos (3,25%); data_inicio_sintomas, com 242.525 (3,59%); e cs_sexo, com 1 registro nulo. A ausência de data de início de sintomas em mais de 240 mil registros é relevante para qualquer análise temporal da pandemia.

Ausência disfarçada de categoria ('IGNORADO'). As 13 colunas de comorbidade registram a ausência de informação como o valor textual IGNORADO, que predomina de forma extrema. A tabela a seguir apresenta a distribuição e a taxa de preenchimento de cada coluna na base completa:

Comorbidade	IGNORADO	SIM	NÃO	Preenchimento
asma	96,5%	0,2%	3,3%	3,5%
cardiopatia	91,5%	7,0%	1,5%	8,5%

Comorbidade	IGNORADO	SIM	NÃO	Preenchimento
diabetes	93,2%	4,7%	2,1%	6,8%
doenca_hematologica	96,6%	0,1%	3,4%	3,4%
doenca_hepatica	96,6%	0,1%	3,4%	3,4%
doenca_neurologica	96,5%	0,4%	3,2%	3,5%
doenca_renal	96,3%	0,5%	3,2%	3,7%
imunodepressao	96,2%	0,6%	3,3%	3,8%
obesidade	96,4%	0,7%	2,9%	3,6%
outros_fatores_de_risco	95,8%	2,3%	1,9%	4,2%
pneumopatia	96,5%	0,3%	3,2%	3,5%
puerpera	96,6%	0,0%	3,4%	3,4%
sindrome_de_down	96,6%	0,0%	3,4%	3,4%

Achado crítico - viés de preenchimento. Ao desconsiderar os registros IGNORADO e analisar apenas os casos com informação conhecida, observa-se que o campo tende a ser preenchido sobretudo quando a comorbidade está presente, e que esse comportamento varia conforme a doença. Entre os casos conhecidos, a proporção de SIM é de 82,3% em cardiopatia, 68,7% em diabetes e 54,6% em outros fatores de risco - nesses campos a anotação ocorre quase só quando há a condição. Já em comorbidades como puérpera (0,8% SIM entre os conhecidos), síndrome de Down (0,6%), doença hematológica (2,0%) e doença hepática (2,1%), a maioria dos registros conhecidos é NÃO. A asma fica em patamar intermediário (6,9% SIM).

Isso demonstra que **o comportamento de preenchimento varia por coluna** e que **‘IGNORADO’ não pode ser tratado como ‘NÃO’** - fazê-lo subestimaria artificialmente a prevalência real das doenças, sobretudo das mais comuns (cardiopatia e diabetes).

Impacto para a sociedade: se a ausência fosse interpretada como negativa, qualquer estatística de prevalência de comorbidades ou de mortalidade associada ficaria distorcida, induzindo conclusões equivocadas em decisões de saúde pública.

3.2 Dados duplicados

A base contém **2.172.256 linhas integralmente idênticas (32,2% dos registros)**. Esse é um dos achados mais delicados da análise e exige interpretação cuidadosa, pois há duas explicações possíveis - e a decisão de remover ou manter esses registros tem consequências opostas:

1. **Notificações duplicadas (erro de dados):** o mesmo caso pode ter sido lançado mais de uma vez no sistema de origem.
2. **Indivíduos distintos que coincidem em todos os campos:** a base não possui identificador único de paciente e descreve cada pessoa por poucos atributos de baixa cardinalidade (município, idade em anos, sexo, data de início de sintomas, óbito e o perfil de comorbidades - quase sempre IGNORADO). Em municípios populosos, é estatisticamente esperado que, em um mesmo dia,

várias pessoas de mesma idade e sexo, com comorbidades não preenchidas, apareçam como linhas idênticas sem que sejam a mesma pessoa.

Dado que a maioria das colunas é IGNORADO ou de baixa granularidade, uma fração expressiva dessas “duplicatas” é provavelmente composta por **pessoas reais distintas**, e não por erros. Por isso, sem um identificador único, é impossível distinguir um lançamento repetido de um caso legítimo, e excluir os 2,17 milhões de registros levaria a uma subcontagem grave dos casos, corrompendo o sinal epidemiológico da base.

A recomendação é **manter os registros e documentar explicitamente essa característica** como uma limitação da base de origem, alertando os reusuários de que a contagem é por registro de notificação, não por indivíduo.

3.3 Erros e inconsistências

Codificação heterogênea entre colunas. A coluna óbito usa codificação numérica (0/1), enquanto as 13 comorbidades usam texto (SIM/NÃO/IGNORADO). Não há um padrão único para representar informação de presença/ausência.

Formato de data com componente inútil. A coluna data_inicio_sintomas é armazenada como 2020-05-25T00:00:00Z. O componente de hora é sempre 00:00:00Z e não carrega informação, dificultando o uso direto do campo como data.

A coluna diagnostico_covid19 apresenta o valor CONFIRMADO em todos os 6.752.117 registros, não agregando informação discriminante (reflexo de um filtro de casos confirmados já aplicado na origem) por isso a mesma será removida no tratamento dos dados.

3.4 Problemas estruturais

Redundância de município e código IBGE. As colunas nome_munic e codigo_ibge mantêm relação 1:1. Armazenar o nome do município em cada linha gera redundância e risco de inconsistência (grafias divergentes para o mesmo código), além de desperdício de espaço em uma base de milhões de registros.

Tipagem inadequada. A coluna idade é interpretada como decimal devido à presença de valores nulos, quando deveria ser inteiro.

4 Transformação e Limpeza - Processo ETL

4.1 Extração

Leitura do arquivo CSV de origem com separador “;”, reconhecendo NA como valor nulo e controlando explicitamente os tipos e a codificação. Para o volume de 6,75 milhões de registros.

4.2 Transformação

- **Datas:** conversão de data_inicio_sintomas para tipo data puro (AAAA-MM-DD), removendo o componente de hora; derivação dos campos ano_sintomas e mes_sintomas para facilitar análises temporais.
- **Idade:** conversão para inteiro com suporte a nulo (tipo Int64); os valores ausentes são mantidos como nulos, sinalizando a falta em vez de mascará-la.

- **Coluna constante:** remoção de `diagnostico_covid19` por ausência de variabilidade.

4.3 Padronização

- **Comorbidades em três estados:** padronização de SIM/NÃO/IGNORADO para o esquema explícito Sim / Não / Desconhecido, preservando a distinção entre ausência da doença e informação indisponível.
- **Óbito:** conversão de 0/1 para Não/Sim; por ser um campo totalmente preenchido, adota-se representação de dois estados (sem categoria de desconhecido), tornando a semântica coerente com as demais colunas categóricas.
- **Texto:** padronização de codificação (UTF-8), remoção de espaços e normalização de caixa em `cs_sexo` e nos nomes de municípios.

4.4 Normalização

Separação dos municípios em uma tabela própria (`dim_municipio: codigo_ibge - nome_municipio`), referenciada pela tabela de casos por meio do `codigo_ibge`. Quando um mesmo código apresenta grafias divergentes, adota-se o nome mais frequente, eliminando inconsistências. Isso remove a redundância estrutural identificada na seção 3.4, assim, o nome do município passa a existir em um único lugar.

4.5 Carga em estrutura temporária

A base tratada é exportada no formato `.csv`, para eventualmente ser carregada em um banco `mysql`, pelo tamanho do arquivo, no repositório será disponibilizado uma amostra menor, citado no tópico 2.1, com registros aleatórios.

5 Documentação do Processo

5.1 Scripts utilizados

O processo foi implementado em Python usando a biblioteca `pandas`, que processa o volume de 6,75 milhões de registros em memória sem necessidade de banco de dados na fase de análise.

5.2 Problemas encontrados e soluções aplicadas

Problema	Solução aplicada
IGNORADO predominante mascarando ausência de dado	Modelagem em três estados; ausência tratada como “Desconhecido”, nunca como “Não”
Viés de preenchimento (campo só preenchido quando há a doença)	Cálculos de prevalência feitos somente sobre registros conhecidos, com rótulo explícito

Problema	Solução aplicada
2,17 milhões de linhas idênticas (32%) sem identificador de paciente	Não deduplicar automaticamente; manter os registros e documentar a limitação (contagem por notificação, não por indivíduo)
diagnostico_covid19 constante (CONFIRMADO em 100%)	Documentar a constância e remover a coluna na base tratada
Codificação mista (0/1 vs. SIM/NÃO)	Padronização para esquema categórico consistente
Data com hora inútil (T00:00:00Z)	Conversão para data pura e derivação de ano/mês
Redundância nome_munic/codigo_ibge	Normalização em tabela de municípios (dim_municipio)
idade como decimal por causa de nulos	Tratamento de nulos e conversão para inteiro (Int64)